

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
28.	Técnicas de Detección de Objetos en Vehículos Autónomos	3
28.1.	Introducción	3
28.2.	Fundamentos Teóricos	4
28.3.	Metodología y Análisis de la Literatura	4
28.4.	Conclusiones	5

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 28

Técnicas de Detección de Objetos en el Desarrollo de Sistemas de Navegación para Vehículos Autónomos

Autor: Victor Fernando Roa Carrión

Correo institucional: victor.roa@unl.edu.ec

Técnica asignada: Detección de Objetos

28.1. Introducción

La detección de objetos constituye uno de los componentes fundamentales dentro de los sistemas modernos de conducción autónoma, debido a que permite identificar y localizar elementos relevantes del entorno, tales como peatones, vehículos, señales de tránsito, ciclistas y obstáculos en tiempo real [1, 2]. Esta capacidad resulta esencial para garantizar procesos de navegación seguros, eficientes y adaptativos en escenarios dinámicos de tráfico.

El avance acelerado de las técnicas de aprendizaje profundo ha permitido mejorar significativamente la precisión y velocidad de los sistemas de percepción vehicular. Arquitecturas basadas en redes neuronales convolucionales (CNN), modelos YOLO (*You Only Look Once*), redes Transformer y sistemas híbridos multimodales han demostrado resultados sobresalientes en tareas de detección bidimensional y tridimensional [3–5].

En la actualidad, los vehículos autónomos integran sensores como cámaras RGB, LiDAR y RADAR para obtener información detallada del entorno. La combinación de estas tecnologías posibilita desarrollar modelos robustos capaces de operar incluso bajo condiciones adversas como lluvia, niebla o baja iluminación [6, 7]. Asimismo, los recientes avances en percepción colaborativa y modelos fundacionales han abierto nuevas líneas de investigación enfocadas en la inteligencia contextual y la interpretación semántica del entorno vial [8, 9].

El presente capítulo analiza las principales técnicas de detección de objetos aplicadas al desarrollo de sistemas de navegación autónoma, considerando sus fundamentos teóricos, arquitecturas predominantes, limitaciones técnicas y contribuciones recientes identificadas en la literatura científica especializada.

28.2. Fundamentos Teóricos

La detección de objetos es una tarea de visión por computador cuyo objetivo consiste en identificar simultáneamente la categoría y ubicación espacial de múltiples objetos dentro de una imagen o secuencia de video [4]. Matemáticamente, un detector de objetos puede representarse mediante una función:

$$f(I) = \{(c_i, b_i, s_i)\}_{i=1}^n \quad (28.1)$$

donde I representa la imagen de entrada, c_i corresponde a la clase detectada, b_i define las coordenadas del cuadro delimitador (*bounding box*) y s_i representa el nivel de confianza asociado a la detección.

Las arquitecturas modernas de detección pueden clasificarse en dos grandes grupos: detectores de dos etapas y detectores de una etapa. Los modelos de dos etapas, como Faster R-CNN, generan primero propuestas de regiones y posteriormente realizan la clasificación de objetos. Por otro lado, los modelos de una etapa, como YOLO y SSD, realizan la detección directamente sobre la imagen completa, logrando mayores velocidades de procesamiento en tiempo real [3, 10].

Entre los modelos más utilizados en conducción autónoma destacan las variantes YOLO debido a su equilibrio entre precisión y eficiencia computacional. Investigaciones recientes evidencian mejoras importantes mediante versiones avanzadas como YOLOv8 y YOLO-NAS [11, 12]. Estas arquitecturas incorporan mecanismos de atención, optimización de extracción de características y estrategias híbridas CNN-Transformer para incrementar el rendimiento en escenarios complejos.

En aplicaciones vehiculares también resulta fundamental la detección tridimensional de objetos. Este enfoque emplea información proveniente de sensores LiDAR, RADAR y cámaras múltiples para estimar profundidad, velocidad y orientación espacial de los objetos [5, 13]. La integración multimodal puede expresarse mediante:

$$F = \alpha C + \beta L + \gamma R \quad (28.2)$$

donde C representa la información de cámaras, L los datos LiDAR, R la información RADAR y α , β , γ corresponden a coeficientes de ponderación utilizados durante la fusión sensorial.

Las técnicas basadas en Transformers también han adquirido relevancia debido a su capacidad para modelar relaciones espaciales globales y dependencias contextuales complejas [14, 15]. Estas arquitecturas permiten mejorar significativamente la percepción en entornos urbanos altamente dinámicos.

Otro aspecto crítico corresponde a la seguridad y robustez de los sistemas de percepción. Los modelos actuales pueden verse afectados por ataques adversariales, desenfoque de lentes, variaciones climáticas o tráfico denso [16–18]. Por ello, las investigaciones recientes priorizan el desarrollo de algoritmos resilientes y sistemas de percepción colaborativa capaces de compartir información entre vehículos conectados [8, 19].

28.3. Metodología y Análisis de la Literatura

La metodología utilizada en este capítulo se fundamentó en una revisión sistemática de literatura científica indexada en bases de datos de alto impacto como IEEE Xplore y IEEE Access. Se seleccionaron investigaciones publicadas entre los años 2020 y 2026 relacionadas con detección de objetos, percepción vehicular, visión por computador y navegación autónoma.

Durante el proceso de revisión se identificaron cuatro líneas principales de investigación: detección bidimensional en tiempo real, detección tridimensional multimodal, robustez frente a condiciones adversas y modelos basados en Transformers y percepción colaborativa.

Los estudios analizados evidencian que los modelos YOLO continúan liderando las aplicaciones en tiempo real debido a su alta velocidad de inferencia y eficiencia computacional [3, 20]. En particular, investigaciones recientes muestran mejoras significativas utilizando arquitecturas híbridas CNN-Transformer que optimizan simultáneamente precisión y velocidad [11].

Por otra parte, la integración de sensores múltiples representa una tendencia dominante en sistemas avanzados de conducción autónoma. La combinación de LiDAR, RADAR y cámaras permite incrementar la robustez del sistema ante escenarios complejos de tráfico y variaciones ambientales [6, 21]. Asimismo, el uso de mecanismos de atención y aprendizaje profundo multimodal mejora considerablemente la detección tridimensional [5, 22].

En relación con las condiciones climáticas adversas, varios autores reportan disminuciones importantes en la precisión de detección bajo lluvia intensa, niebla y baja iluminación [7, 18]. Estas limitaciones motivan el desarrollo de algoritmos robustos capaces de adaptarse dinámicamente a diferentes contextos ambientales.

La Tabla 28.1 resume las principales características observadas en las técnicas de detección estudiadas.

Tabla 28.1: Comparación de técnicas de detección de objetos en vehículos autónomos.

Técnica	Ventajas	Limitaciones
YOLO	Alta velocidad en tiempo real	Sensibilidad ante objetos pequeños
Faster R-CNN	Elevada precisión	Mayor costo computacional
LiDAR + Cámara	Mejor percepción 3D	Alto costo de implementación
Transformers	Mejor análisis contextual	Requiere grandes volúmenes de datos
Percepción colaborativa	Mayor robustez y cobertura	Dependencia de conectividad vehicular

De igual manera, las investigaciones recientes destacan el crecimiento de modelos fundacionales y modelos visión-lenguaje para conducción autónoma, los cuales permiten interpretar escenas complejas mediante razonamiento semántico avanzado [9, 15]. Estas tecnologías representan una evolución importante hacia sistemas de navegación más inteligentes y autónomos.

28.4. Conclusiones

Las técnicas de detección de objetos desempeñan un papel fundamental en el desarrollo de sistemas modernos de navegación para vehículos autónomos, debido a que permiten interpretar el entorno vial y ejecutar decisiones seguras en tiempo real.

Los avances en aprendizaje profundo han impulsado el desarrollo de arquitecturas altamente eficientes como YOLO, CNN híbridas y modelos Transformer, capaces de alcanzar elevados niveles de precisión en tareas de percepción vehicular. Asimismo, la integración multimodal de sensores como cámaras, LiDAR y RADAR ha permitido mejorar significativamente la detección tridimensional y la robustez del sistema frente a condiciones adversas.

El análisis de la literatura evidencia que las principales tendencias actuales se orientan hacia la percepción colaborativa, los modelos fundacionales y la integración de inteligencia contextual mediante arquitecturas visión-lenguaje. Sin embargo, aún persisten desafíos relacionados con seguridad, costo computacional, ataques adversariales y desempeño bajo condiciones climáticas extremas.

Finalmente, se concluye que la evolución continua de las técnicas de detección de objetos será determinante para alcanzar niveles superiores de autonomía vehicular, incrementando la seguridad, eficiencia y confiabilidad de los sistemas inteligentes de transporte del futuro.

Referencias

- [1] E. Yurtsever, J. Lambert, A. Carballo, and K. Takeda, “A survey of autonomous driving: <i>common practices and emerging technologies</i>,” *IEEE Access*, vol. 8, pp. 58443–58469, 3 2020.
- [2] H.-H. Jebamikyous and R. Kashef, “Autonomous vehicles perception (avp) using deep learning: Modeling, assessment, and challenges,” *IEEE Access*, vol. 10, pp. 10523–10535, 1 2022.
- [3] L. T. Ramos and A. D. Sappa, “A decade of you only look once (yolo) for object detection: A review,” *IEEE Access*, vol. 13, pp. 192747–192794, 11 2025.
- [4] T. Turay and T. Vladimirova, “Toward performing image classification and object detection with convolutional neural networks in autonomous driving systems: A survey,” *IEEE Access*, vol. 10, pp. 14076–14119, 1 2022.
- [5] A. Pravallika, M. F. Hashmi, and A. Gupta, “Deep learning frontiers in 3d object detection: A comprehensive review for autonomous driving,” *IEEE Access*, vol. 12, pp. 173936–173980, 9 2024.
- [6] R. Sahba, A. Sahba, and F. Sahba, “Using a combination of lidar, radar, and image data for 3d object detection in autonomous vehicles,” in *2020 11th IEEE Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON)*, pp. 0427–0431, IEEE, 11 2020.
- [7] H. Abbasi, M. Amini, and F. R. Yu, “Comprehensive analysis of object detection using rgb camera for autonomous vehicles under adverse weather conditions,” in *2025 IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)*, pp. 602–606, IEEE, 5 2025.
- [8] L. Wan, J. Zhao, A. Wiedholz, M. Bied, M. M. de Lucena, A. D. Jagtap, A. Festag, A. A. Fröhlich, H. E. Keen, and A. Vinel, “A systematic literature review on vehicular collaborative perception—a computer vision perspective,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 27, pp. 81–118, 1 2026.
- [9] R. Sathyam and Y. Li, “Foundation models for autonomous driving perception: A survey through core capabilities,” *IEEE Open Journal of Vehicular Technology*, vol. 6, pp. 2554–2582, 9 2025.
- [10] A. Wibowo, B. R. Trilaksono, E. M. I. Hidayat, and R. Munir, “Object detection in dense and mixed traffic for autonomous vehicles with modified yolo,” *IEEE Access*, vol. 11, pp. 134866–134877, 11 2023.
- [11] M. S. Marri and M. P, “Hybrid cnn-transformer and yolov8-based robust real-time object detection for autonomous vehicles,” in *2025 Innovations in Power and Advanced Computing Technologies (i-PACT)*, pp. 1–7, IEEE, 9 2025.

- [12] T. K. Nowrin, S. Akter, T. Azhar, and M. N. Uddin, “Enhancing object detection for autonomous vehicles using yolo-nas on bangladeshi dataset,” in *2024 International Conference on Innovations in Science, Engineering and Technology (ICISSET)*, pp. 1–6, IEEE, 10 2024.
- [13] L. Alexandrino, H. Z. Olyaei, A. Albuquerque, P. Georgieva, and M. V. Drummond, “3d object detection for self-driving vehicles enhanced by object velocity,” *IEEE Access*, vol. 12, pp. 8220–8229, 1 2024.
- [14] A. Abdulkawsoud and R. Ahmed, “Transformer-based sensor fusion for autonomous vehicles: A comprehensive review,” *IEEE Access*, vol. 13, pp. 41822–41838, 2 2025.
- [15] X. Zhou, M. Liu, E. Yurtsever, B. L. Zagar, W. Zimmer, H. Cao, and A. C. Knoll, “Vision language models in autonomous driving: A survey and outlook,” *IEEE Transactions on Intelligent Vehicles*, pp. 1–20, 5 2025.
- [16] H. Wang, J. Zhang, Y. Wang, and D. Wang, “Secure object detection of autonomous vehicles against adversarial attacks,” in *IECON 2024 - 50th Annual Conference of the IEEE Industrial Electronics Society*, pp. 1–6, IEEE, 11 2024.
- [17] D. Molloy, P. Müller, B. Deegan, D. Mullins, J. Horgan, E. Ward, E. Jones, A. Braun, and M. Glavin, “Analysis of the impact of lens blur on safety-critical automotive object detection,” *IEEE Access*, vol. 12, pp. 3554–3569, 1 2024.
- [18] T. Sharma, A. Chehri, I. Fofana, S. Jadhav, S. Khare, B. Debaque, N. Duclos-Hindie, and D. Arya, “Deep learning-based object detection and classification for autonomous vehicles in different weather scenarios of quebec, canada,” *IEEE Access*, vol. 12, pp. 13648–13662, 1 2024.
- [19] A. Solanki, W. A. Amiri, M. Mahmoud, B. Swieder, S. R. Hasan, and T. N. Guo, “Survey of navigational perception sensors’ security in autonomous vehicles,” *IEEE Access*, vol. 13, pp. 104937–104965, 6 2025.
- [20] H. Ren, F. Jing, and S. Li, “Dcw-yolo: Road object detection algorithms for autonomous driving,” *IEEE Access*, vol. 13, pp. 125676–125688, 2 2025.
- [21] H. Mushtaq, S. Latif, M. S. B. Ilyas, S. M. Mohsin, and M. Ali, “Cls-3d: Content-wise lidar-camera fusion and slot reweighting transformer for 3d object detection in autonomous vehicles,” *IEEE Access*, vol. 13, pp. 69840–69856, 4 2025.
- [22] A. Hazarika, A. Vyas, M. Rahmati, and Y. Wang, “Multi-camera 3d object detection for autonomous driving using deep learning and self-attention mechanism,” *IEEE Access*, vol. 11, pp. 64608–64620, 1 2023.