

Descripción del Problema Técnico

Técnica de IA: Detección de Objetos

Pregunta de investigación: ¿Cómo se aplica la detección de objetos en sistemas de vehículos autónomos?

Nombre: Victor Roa

Fecha: 29/04/2026

Curso: 4to Ciclo, Computación

1. Contexto general del problema

En el contexto de los Sistemas Inteligentes y la Inteligencia Artificial Aplicada, la industria del transporte y la movilidad autónoma enfrenta desafíos de alta complejidad relacionados con la percepción del entorno en tiempo real, especialmente en entornos viales dinámicos e impredecibles. Los vehículos autónomos (VA) requieren sistemas capaces de identificar, clasificar y localizar con precisión objetos como peatones, otros vehículos, señales de tránsito y obstáculos, todo ello en fracciones de segundo y bajo condiciones variables. La detección de objetos, como técnica central de la visión computacional y el aprendizaje profundo, se posiciona como uno de los componentes más críticos de la arquitectura perceptual de estos sistemas [1, 2, 3]. Este problema tiene relevancia tanto en entornos industriales —fabricantes de automóviles y empresas tecnológicas— como en entornos de investigación académica, donde se busca mejorar continuamente la robustez, velocidad y seguridad de los algoritmos de detección.

2. Situación actual basada en evidencia

Diversos estudios han evidenciado avances significativos en la aplicación de técnicas de detección de objetos para vehículos autónomos. Por un lado, la fusión de múltiples modalidades de sensores —como LiDAR, RADAR y cámaras RGB— ha demostrado mejorar sustancialmente la precisión en la detección tridimensional de objetos [2], dado que cada sensor compensa las limitaciones del otro: el LiDAR ofrece profundidad precisa, el RADAR funciona bien bajo lluvia o niebla, y las cámaras aportan riqueza semántica. Por otro lado, arquitecturas modernas como YOLO-NAS han mostrado resultados prometedores en entornos con características geográficas y de tránsito particulares [4], lo que subraya la importancia de adaptar los modelos a los conjuntos de datos locales.

Asimismo, modelos híbridos que combinan redes neuronales convolucionales (CNN) con arquitecturas Transformer —como la propuesta basada en CNN-Transformer y YOLOv8— han demostrado capacidad para la detección robusta en tiempo real [5]. Sin embargo, persisten limitaciones críticas: los sistemas de detección basados en cámaras RGB presentan degradación severa de rendimiento bajo condiciones meteorológicas adversas como lluvia, niebla y poca iluminación [3], y además son vulnerables a ataques adversariales que pueden engañar a los modelos de detección con perturbaciones imperceptibles al ojo humano [1].

3. Brecha o vacío identificado

A pesar de los avances reportados, existe una brecha significativa en la capacidad de los sistemas de detección de objetos para operar de manera confiable y segura bajo la totalidad de condiciones del mundo real. En primer lugar, los modelos entrenados en conjuntos de datos de

regiones específicas (principalmente europeos o estadounidenses) no generalizan adecuadamente a contextos de tránsito de otros países con características distintas [4]. En segundo lugar, si bien la fusión de sensores mejora la detección 3D, la integración eficiente de LiDAR, RADAR e imagen en arquitecturas unificadas y de bajo costo computacional sigue siendo un reto abierto [2]. En tercer lugar, la vulnerabilidad ante ataques adversariales representa una amenaza real a la seguridad de los vehículos autónomos que aún carece de soluciones generalizables [1]. Finalmente, la robustez de los detectores visuales bajo condiciones climáticas adversas sigue siendo insuficiente para garantizar la seguridad operacional [3].

4. Problema central

El problema radica en que los sistemas actuales de detección de objetos aplicados a vehículos autónomos no logran mantener un nivel de precisión, robustez y seguridad suficiente frente a la variabilidad del entorno real, que incluye condiciones meteorológicas adversas [3], ataques adversariales deliberados [1], diversidad geográfica y cultural del tránsito [4] y la complejidad de integrar múltiples modalidades de sensores en tiempo real [2, 5]. Esto afecta directamente la seguridad de los ocupantes del vehículo, los peatones y otros actores viales, limitando la implementación confiable y masiva de la conducción autónoma.

5. Consecuencias o impacto

Esta situación genera consecuencias graves en múltiples niveles. Desde el punto de vista de la seguridad, la falla en la detección de objetos puede provocar accidentes con consecuencias fatales, especialmente cuando los modelos son engañados por ataques adversariales o fallan ante condiciones de baja visibilidad [1, 3]. Desde el punto de vista técnico, la falta de generalización de los modelos a distintos contextos geográficos —como el tránsito en países en desarrollo— limita la escalabilidad global de las soluciones [4]. Además, la dependencia exclusiva de cámaras RGB, sin integración con otros sensores, reduce la confiabilidad del sistema en escenarios donde la visibilidad se ve comprometida [2]. En conjunto, estos factores retrasan la adopción masiva de vehículos autónomos, incrementan los costos de desarrollo y erosionan la confianza pública en la tecnología [5].

6. Actores involucrados

Los principales actores involucrados en este problema incluyen: los fabricantes de vehículos autónomos y empresas tecnológicas que desarrollan sistemas de percepción; los investigadores y académicos que trabajan en visión por computadora, aprendizaje profundo y seguridad en IA [1, 5]; los organismos reguladores de transporte y seguridad vial que deben establecer estándares mínimos de rendimiento; los conductores y ocupantes de vehículos autónomos cuya seguridad depende directamente de la fiabilidad de la detección; los peatones y otros usuarios de la vía que interactúan con estos vehículos; y las comunidades locales de distintos países, cuyos patrones de tránsito específicos deben ser contemplados en los conjuntos de datos de entrenamiento [4].

7. Variables o elementos clave

Las variables clave asociadas al problema incluyen:

- Precisión de detección (mAP — mean Average Precision): métrica central para evaluar el rendimiento de los modelos de detección de objetos [1, 4, 5].

- Robustez ante condiciones adversas: capacidad del sistema para mantener su rendimiento bajo lluvia, niebla, noche u otras condiciones de baja visibilidad [3].
- Seguridad ante ataques adversariales: resistencia de los modelos frente a perturbaciones intencionales diseñadas para provocar errores de detección [1].
- Modalidad de sensores: tipo y combinación de sensores utilizados (cámara RGB, LiDAR, RADAR) y su impacto en la detección 3D [2].
- Latencia de inferencia: tiempo de procesamiento del modelo, crítico para la respuesta en tiempo real en vehículos en movimiento [5].
- Generalización geográfica: capacidad del modelo para funcionar correctamente en contextos de tránsito distintos a los del conjunto de datos de entrenamiento [4].

8. Delimitación del problema

El presente problema se delimita al análisis y mejora de técnicas de detección de objetos —con énfasis en modelos basados en aprendizaje profundo como YOLO y arquitecturas CNN-Transformer [4, 5]— aplicadas específicamente al subsistema de percepción de vehículos autónomos, en contextos viales urbanos y suburbanos. Se contempla el uso de datos provenientes de cámaras RGB [3], así como la integración multimodal con LiDAR y RADAR [2]. El problema excluye los subsistemas de planificación de ruta, control de actuadores y comunicación vehículo-a-vehículo (V2V), así como aspectos puramente legales o regulatorios de la conducción autónoma. También queda fuera del alcance el diseño de hardware de sensores.

9. Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación de *Sistemas Inteligentes y Visión por Computadora*, debido a su enfoque en el desarrollo y evaluación de modelos de aprendizaje profundo para la percepción autónoma del entorno. La detección de objetos constituye un problema central de la inteligencia artificial aplicada, que integra técnicas de redes neuronales convolucionales, transformers y fusión de sensores [2, 5]. La relevancia de esta sublínea se justifica por la necesidad urgente de desarrollar sistemas seguros [1], precisos [4] y robustos [3] que soporten la toma de decisiones en vehículos autónomos en condiciones del mundo real.

Bibliografía

- [1] H. Wang, J. Zhang, Y. Wang, and D. Wang, "Secure Object Detection of Autonomous Vehicles Against Adversarial Attacks," in IECON 2024 - 50th Annual Conference of the IEEE Industrial Electronics Society, IEEE, Nov. 2024, pp. 1–6. doi: 10.1109/IECON55916.2024.10905242.
- [2] R. Sahba, A. Sahba, and F. Sahba, "Using a Combination of LiDAR, RADAR, and Image Data for 3D Object Detection in Autonomous Vehicles," in 2020 11th IEEE Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON), IEEE, Nov. 2020, pp. 0427–0431. doi: 10.1109/IEMCON51383.2020.9284930.
- [3] H. Abbasi, M. Amini, and F. R. Yu, "Comprehensive Analysis of Object Detection using RGB Camera for Autonomous Vehicles under Adverse Weather Conditions," in 2025

IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), IEEE, May 2025, pp. 602–606. doi: 10.1109/CCECE64018.2025.11364514.

- [4] T. K. Nowrin, S. Akter, T. Azhar, and M. N. Uddin, "Enhancing Object Detection for Autonomous Vehicles Using YOLO-NAS on Bangladeshi Dataset," in 2024 International Conference on Innovations in Science, Engineering and Technology (ICISSET), IEEE, Oct. 2024, pp. 1–6. doi: 10.1109/ICISSET62123.2024.11003917.
- [5] M. S. Marri and M. P, "Hybrid CNN-Transformer and YOLOv8-Based Robust Real-Time Object Detection for Autonomous Vehicles," in 2025 Innovations in Power and Advanced Computing Technologies (i-PACT), IEEE, Sep. 2025, pp. 1–7. doi: 10.1109/i-PACT65952.2025.11307825.